



Collège Sciences et Technologies
UF Mathématiques et Interactions

Projet de fin de module – Mixture of Experts (MoE)

Paul-Henri Leplomb
Enzo Quattrochi

M2 CMI OPTIM

2025 – 2026

Architectures de réseaux de neurones avancées

Table des matières

1	Introduction et revue du concept de Mixture of Experts	3
2	Description du modèle	3
2.1	Vue d'ensemble de l'architecture	3
2.2	Représentation des données en entrée	3
2.3	Architecture des experts	3
2.4	Réseau de gating et stratégie de routage	4
2.5	Combinaison des sorties	4
2.6	Modèle dense de référence	4
3	Protocole expérimental et hyperparamètres	4
4	Résultats expérimentaux et interprétation	5
4.1	Comparaison globale des performances	5
4.2	Analyse qualitative	5
4.3	Visualisation et spécialisation du gating	6
4.4	Analyse spécifique aux modèles MoE	6
4.5	Interprétation des compromis	7
5	Discussion critique	7

1 Introduction et revue du concept de Mixture of Experts

Les réseaux de neurones profonds classiques reposent généralement sur une architecture dite dense, dans laquelle l'ensemble des paramètres du modèle est sollicité pour chaque donnée d'entrée. Cette approche présente l'avantage de la simplicité et de la stabilité à l'entraînement, mais elle devient rapidement coûteuse lorsque l'on cherche à augmenter la capacité du modèle. En effet, accroître la taille d'un réseau dense implique une augmentation proportionnelle du nombre de paramètres et du coût de calcul à chaque passage avant.

Les architectures de type *Mixture of Experts* (MoE) proposent une alternative à cette limitation en introduisant le principe de *computation conditionnelle*. L'idée centrale consiste à remplacer un bloc dense unique par un ensemble de sous-modèles spécialisés, appelés experts, et à apprendre un mécanisme de routage chargé de déterminer quels experts doivent être mobilisés pour une entrée donnée. Ainsi, seule une partie du modèle est réellement utilisée à chaque inférence.

Ce principe a été introduit dès les années 1990, notamment dans les travaux sur les mélanges d'experts adaptatifs, puis remis au premier plan avec l'émergence de modèles très larges en apprentissage profond. Des architectures modernes telles que les Switch Transformers ou les modèles sparsely-gated exploitent cette idée afin d'augmenter massivement la capacité des réseaux tout en maîtrisant leur coût d'inférence.

L'objectif de ce projet est d'implémenter et d'analyser un modèle MoE simple dans un cadre contrôlé, afin de mieux comprendre le fonctionnement du routage, la spécialisation des experts et les compromis par rapport à une architecture dense classique. Pour cela, nous considérons une tâche de classification d'images sur le jeu de données MNIST.

2 Description du modèle

2.1 Vue d'ensemble de l'architecture

Le modèle proposé repose sur une unique couche de type Mixture of Experts, intégrée directement comme architecture de classification. Cette couche est construite autour de quatre experts indépendants, chacun chargé de produire une prédiction complète à partir de l'entrée. Le fonctionnement du modèle est piloté par un réseau de gating, dont le rôle est de calculer, pour chaque donnée en entrée, un ensemble de poids associés aux différents experts. Ces poids sont ensuite utilisés pour combiner les sorties individuelles des experts afin d'obtenir la prédiction finale du modèle.

Le choix d'une architecture volontairement simple permet de se concentrer sur l'analyse du comportement interne du MoE, en particulier sur le rôle du gating et la spécialisation des experts. Cette simplicité évite également d'introduire des sources de complexité supplémentaires liées à l'utilisation de couches convolutionnelles ou d'architectures plus profondes, qui pourraient rendre l'interprétation des résultats plus difficile.

2.2 Représentation des données en entrée

Les images MNIST sont des images en niveaux de gris de taille 28×28 . Dans ce projet, elles sont aplaties en vecteurs de dimension 784 avant d'être fournies au réseau. Ce choix est cohérent avec l'utilisation de perceptrons multi-couches et permet une comparaison directe avec un modèle dense de référence basé sur la même représentation.

Bien que cette approche ne soit pas optimale pour des tâches de vision plus complexes, elle est suffisante dans le cadre de MNIST et facilite l'interprétation des résultats.

2.3 Architecture des experts

Chaque expert est implémenté sous la forme d'un MLP composé de trois couches linéaires successives. Les deux premières couches sont suivies d'une fonction d'activation ReLU, tandis que la dernière couche produit directement les logits de classification.

Les dimensions choisies ($784 \rightarrow 128 \rightarrow 128 \rightarrow 10$) résultent d'un compromis entre capacité et simplicité. Tous les experts partagent la même architecture, mais disposent de paramètres indépendants, ce qui leur permet de se spécialiser sur différentes régions de l'espace des données.

Ce choix d’experts homogènes permet d’attribuer les différences de comportement observées uniquement au mécanisme de routage, et non à des différences structurelles entre experts.

2.4 Réseau de gating et stratégie de routage

Le réseau de gating joue un rôle central dans l’architecture MoE. Il reçoit la même entrée que les experts et produit un score pour chacun d’eux. Dans notre implémentation, le gating est un MLP simple composé d’une couche cachée de 64 neurones suivie d’une couche de sortie de dimension égale au nombre d’experts.

Les scores produits sont transformés en probabilités à l’aide d’une fonction softmax, garantissant que les poids attribués aux experts somment à 1. Ces probabilités sont ensuite utilisées pour effectuer une combinaison linéaire des sorties des experts.

Ce choix correspond à un routage *soft*, dans lequel tous les experts contribuent à la sortie finale, mais avec des poids différents. Cette approche présente l’avantage d’être entièrement différentiable, ce qui facilite l’entraînement conjoint du gating et des experts par rétropropagation.

2.5 Combinaison des sorties

Les sorties produites par chaque expert sont empilées puis combinées par une somme pondérée. Formellement, la sortie finale du modèle s’écrit :

$$y = \sum_{i=1}^N g_i(x) E_i(x)$$

où $E_i(x)$ représente la sortie de l’expert i et $g_i(x)$ le poids associé par le gating.

Cette formulation permet une interprétation simple du fonctionnement du modèle : le gating agit comme un mécanisme d’attention distribuant l’importance relative de chaque expert pour une entrée donnée.

2.6 Modèle dense de référence

Afin d’évaluer l’intérêt du MoE, un modèle dense classique est implémenté comme baseline. Il s’agit d’un MLP composé de deux couches cachées de 256 neurones chacune, suivies d’une couche de sortie de dimension 10.

Ce modèle utilise la même représentation d’entrée et la même fonction de perte que le MoE, ce qui permet une comparaison équitable des performances. Sa capacité est volontairement comparable à celle du MoE afin d’éviter un biais lié au nombre de paramètres.

3 Protocole expérimental et hyperparamètres

Les expériences sont menées sur le jeu de données MNIST, séparé en un ensemble d’entraînement et un ensemble de test. Les données sont chargées à l’aide de mini-batches afin de stabiliser l’entraînement.

Pour tous les modèles, l’optimiseur Adam est utilisé avec un taux d’apprentissage fixé à 10^{-3} . Le choix de cet optimiseur repose sur sa robustesse et son usage courant dans les tâches de classification supervisée. La fonction de perte employée est l’entropie croisée, adaptée aux problèmes de classification multi-classes.

Les modèles sont entraînés pendant cinq époques, ce qui est suffisant pour atteindre une convergence satisfaisante sur MNIST. Les performances sont évaluées en termes d’accuracy sur les ensembles d’entraînement et de test.

Dans une seconde série d’expériences, une régularisation par entropie est ajoutée au modèle MoE. Cette pénalité vise à contrôler la distribution des poids du gating et à éviter une spécialisation trop extrême ou, au contraire, une domination systématique d’un seul expert.

4 Résultats expérimentaux et interprétation

Cette section présente les résultats expérimentaux obtenus lors de la comparaison entre le modèle dense et les différentes variantes du modèle Mixture of Experts. Les performances sont analysées à l’aide de métriques quantitatives classiques, telles que l’accuracy, le nombre d’erreurs et le temps d’inférence, ainsi que par l’étude du comportement interne du mécanisme de gating.

4.1 Comparaison globale des performances

Le tableau 1 synthétise l’ensemble des résultats obtenus pour les trois modèles étudiés : le modèle dense, le MoE simple et le MoE avec régularisation par entropie.

Modèle	Accuracy	Nb erreurs	Temps inférence (s)
Dense	0.9805	22	1.387
MoE simple	0.9762	28	1.508
MoE régularisé	0.9763	28	1.495

TABLE 1 – Comparaison globale des performances entre le modèle dense et les variantes du modèle Mixture of Experts

Les résultats montrent que le modèle dense obtient la meilleure accuracy ainsi que le plus faible nombre d’erreurs sur le jeu de test. Les deux variantes du modèle MoE atteignent des performances légèrement inférieures, avec une différence de quelques dixièmes de pourcentage, ce qui reste modéré dans le cadre de la tâche MNIST.

En termes de temps d’inférence, le modèle dense est également le plus rapide. Le surcoût observé pour les modèles MoE s’explique par l’activation simultanée de plusieurs experts lors du routage soft, impliquant davantage de calculs à chaque passage avant.

4.2 Analyse qualitative




FIGURE 1 – Comparaison qualitative des erreurs de classification pour le modèle dense, le MoE simple et le MoE régularisé. Pour chaque image, la classe vraie (v) et la classe prédite (p) sont indiquées.

La figure 1 présente une sélection d’images mal classifiées par les différents modèles. On observe que les erreurs concernent majoritairement des chiffres ambigus ou mal écrits, pour lesquels même un observateur humain peut hésiter. Cela confirme que les erreurs restantes ne sont pas dues à un manque d’apprentissage global, mais plutôt à des cas limites du jeu de données.

Les types d’erreurs observés sont globalement similaires entre le modèle dense et les modèles MoE. Aucun modèle ne semble systématiquement se tromper sur une classe particulière, ce qui est cohérent avec les différences relativement faibles observées en termes d’accuracy globale.

Cette analyse qualitative permet de relativiser les écarts numériques entre les modèles et montre que le MoE n’introduit pas de biais évident dans la nature des erreurs commises.

4.3 Visualisation et spécialisation du gating




FIGURE 2 – Heatmaps des poids moyens du gating en fonction des classes pour le MoE simple et le MoE régularisé. Chaque ligne correspond à un chiffre MNIST et chaque colonne à un expert.

La figure 2 montre les heatmaps des poids moyens attribués par le réseau de gating aux différents experts, pour chaque classe de chiffres, dans le cas du MoE simple et du MoE régularisé.

Dans le modèle MoE simple, la distribution des poids reste relativement diffuse. Bien que certaines préférences apparaissent, plusieurs experts contribuent de manière significative pour une même classe, ce qui traduit une spécialisation encore partielle.

À l’inverse, le MoE régularisé présente des heatmaps plus contrastées. Certaines classes sont majoritairement associées à un expert particulier, tandis que les autres experts ont des poids nettement plus faibles. Cette observation est cohérente avec la diminution de l’entropie moyenne du gating mesurée quantitativement, et confirme que la régularisation par entropie favorise une spécialisation plus marquée des experts.

Ces visualisations renforcent l’analyse quantitative et montrent que la régularisation agit principalement sur la structure interne du modèle, sans dégrader significativement les performances globales.

4.4 Analyse spécifique aux modèles MoE

Au-delà de la performance brute, les modèles Mixture of Experts se distinguent par leur comportement interne. Le tableau 2 présente l’entropie moyenne du réseau de gating pour les deux variantes du MoE.

Modèle MoE	Entropie moyenne du gating
MoE simple	0.7089
MoE régularisé	0.6240

TABLE 2 – Entropie moyenne du gating pour les modèles Mixture of Experts

L’entropie plus élevée observée pour le MoE simple indique une distribution plus diffuse des poids du gating, traduisant une utilisation relativement équilibrée mais peu spécialisée des experts. À l’inverse, la régularisation par entropie conduit à une diminution notable de cette valeur, suggérant une distribution plus structurée et une spécialisation plus marquée des experts.

Il est intéressant de noter que cette modification du comportement interne n’entraîne pas de dégradation significative des performances en termes d’accuracy. La régularisation permet ainsi de contrôler le routage tout en conservant des performances comparables à celles du MoE non régularisé.

4.5 Interprétation des compromis

Ces résultats mettent en évidence plusieurs compromis inhérents aux architectures Mixture of Experts. D’une part, le modèle dense reste plus efficace sur une tâche simple comme MNIST, à la fois en termes de performance et de temps d’inférence. D’autre part, le MoE introduit une modularité interne et une spécialisation des sous-réseaux qui ne sont pas capturées par les métriques globales.

Le surcoût en temps d’inférence observé dans le cas du MoE est directement lié au choix d’un routage soft. Ce comportement ouvre la voie à des extensions futures, telles que l’utilisation d’un routage hard top-1 ou top-k, qui permettrait de réduire significativement le coût de calcul tout en conservant les bénéfices de la spécialisation.

5 Discussion critique

Ce travail met en évidence les avantages et les limites des architectures Mixture of Experts dans un cadre simple. Le MoE permet d’introduire une forme de modularité et de spécialisation interne, tout en restant compatible avec un entraînement classique par descente de gradient.

Néanmoins, sur une tâche aussi simple que MNIST, le gain par rapport à un modèle dense reste limité. Cela s’explique par le fait que la complexité de la tâche ne nécessite pas une capacité très élevée.

Par ailleurs, le routage soft utilisé ici implique que tous les experts sont activés à chaque passage, ce qui limite les gains potentiels en termes de coût de calcul. Une extension naturelle serait l’utilisation d’un routage hard de type top-1 ou top-k, permettant une activation parcimonieuse des experts.

Enfin, l’intégration d’une couche MoE dans des architectures plus complexes, telles que des réseaux convolutionnels ou des Transformers, constitue une perspective intéressante pour exploiter pleinement le potentiel de cette approche.